

De p-waarde, het significantieniveau en de twee fouten

Hoe je beslist, waar de grens ligt, en wat er mis kan gaan als je beslist.

1 De p-waarde

Bij een **hypothesetoets** draait alles rond één getal. De **p-waarde** is de kans op een resultaat dat **minstens zo extreem** is als het gevondene, **als H0 waar is**. Dat laatste stukje is het belangrijkste van de hele zin.

Vind je bij een rechtszijdige toets een steekproefgemiddelde van 52 terwijl H0 zegt dat mu gelijk is aan 50, dan is de p-waarde de **kans op een steekproefgemiddelde van 52 of meer onder H0**. Je rekent ze uit met de rekenapps, maar je **noteert wel je werkwijze en je redenering**.

De fout die iedereen maakt. "De p-waarde is 0,04, dus er is vier procent kans dat H0 waar is." Dat staat er niet. De p-waarde is **de kans op de data als H0 waar is**, niet de kans dat H0 waar is.

Een p-waarde van 0,001 betekent dus: **zulke data komen in één op de duizend gevallen voor als H0 waar is**.

Een p-waarde is een kans, dus ze ligt tussen nul en één. Ze **kan nooit groter zijn dan één**, hoe groot het gevonden verschil ook is. Een **kleinere p-waarde betekent sterker bewijs tegen H0**.

2 Het significantieniveau alfa

Het **significantieniveau alfa** is de grens waaronder je de nulhypothese verwerpt. Het meest gebruikte niveau is **0,05**.

Verwerp H_0 als de p-waarde kleiner is dan of gelijk aan alfa.

Is de p-waarde **groter** dan alfa, dan verwerp je H_0 **niet**. Bij een p-waarde van precies 0,05 met alfa gelijk aan 0,05 verwerp je H_0 dus wél: de grens hoort erbij.

p-waarde	alfa	Besluit
0,03	0,05	H_0 verwerpen
0,05	0,05	H_0 verwerpen
0,07	0,05	H_0 niet verwerpen
0,12	0,05	H_0 niet verwerpen, er is te weinig bewijs tegen

Alfa gelijk aan 0,01 is **strenger** dan 0,05: je hebt sterker bewijs nodig voor je H_0 verwerpt. Je kiest alfa **vooraf**. Kies je het pas nadat je de p-waarde kent, dan kan je alfa zo kiezen dat je gewenste besluit uitkomt, en dan is de hele toets theater.

 **Weetje.** Bij een **tweezijdige** toets vergelijk je de p-waarde gewoon met **alfa**, niet met alfa gedeeld door twee. Het opsplitsen gebeurt al bij het berekenen van de p-waarde zelf: die telt allebei de staarten mee.

3 De twee fouten

H0 is waar — je verwerpt ze niet

- juiste beslissing
- de onschuldige gaat vrijuit

H0 is waar — je verwerpt ze

- type I-fout, kans gelijk aan alfa
- de onschuldige wordt veroordeeld

H0 is fout — je verwerpt ze niet

- type II-fout
- de rookmelder zwijgt terwijl er brand is

H0 is fout — je verwerpt ze

- juiste beslissing
- de schuldige wordt veroordeeld

Links beslis je niet te verwerpen, rechts wel. Boven geldt H0 echt, onder niet.

De vier mogelijke afloopjes van een toets. Per toets gebeurt er hoogstens één van de twee fouten, want H0 is waar of ze is het niet.

Een **type I-fout** is H0 verwerpen terwijl ze waar is. De kans erop is **gelijk aan alfa**. Bij alfa gelijk aan 0,05 verwerp je dus gemiddeld **één op de twintig keer** een nulhypothese die waar is.

Een **type II-fout** is H0 niet verwerpen terwijl ze fout is. Een medische test die een gezonde patiënt ziek noemt, is een type I-fout als H0 zegt dat de patiënt gezond is. Een rookmelder die niet afgaat terwijl er brand is, is een type II-fout als H0 zegt dat er geen brand is.

De twee fouten **kunnen niet tegelijk gebeuren** bij dezelfde toets: H0 is waar of ze is het niet. Maar ze trekken wel aan elkaar. **Kleiner alfa kiezen verkleint de kans op een type I-fout en vergroot die op een type II-fout**. Een fabrikant die vooral wil vermijden dat hij een goede partij afkeurt, **maakt alfa kleiner**.

 **Weetje.** Er is één manier om de kans op **allebei** de fouten tegelijk te verkleinen: **een grotere steekproef nemen**. Dat is de hele reden waarom grote onderzoeken meer waard zijn.

4 Je besluit correct opschrijven

H0 niet verwerpen is iets anders dan H0 aanvaarden. Het kan ook aan een te kleine steekproef liggen in plaats van aan de waarheid van H0. Schrijf dus niet "er is geen verschil" maar "**er is te weinig bewijs voor een verschil**" — een verschil kan er wel degelijk zijn, je hebt het alleen niet aangetoond.

Een goed besluit noemt **het niveau** erbij: "op het niveau van vijf procent is er voldoende bewijs dat het gemiddelde hoger is". Zonder dat niveau weet je lezer niet hoe streng je was.

Valkuil	Wat er mis is
"het effect is groot, want p is heel klein"	een significant resultaat zegt niet hoe groot het effect is
een verschil van 0,1 % met $p = 0,001$ bij honderdduizend deelnemers	significant, maar praktisch misschien onbelangrijk
twintig verbanden toetsen op $\alpha = 0,05$ en er één significant vinden	bij twintig toetsen verwacht je er al één door toeval
" $p = 0,07$, dus er is geen verschil"	er is te weinig bewijs, dat is iets anders

Dat eerste en dat tweede horen bij elkaar: bij een **grote steekproef** wordt een klein verschil al snel significant. Twee onderzoeken die hetzelfde verschil vinden, het ene met n gelijk aan dertig en het andere met n gelijk aan drieduizend, geven bij het **grote onderzoek de kleinste p-waarde. Significant en belangrijk zijn twee verschillende dingen.**

Onthoud dit

- De p-waarde is de kans op minstens zo'n extreem resultaat als H_0 waar is. Niet de kans dat H_0 waar is.
- Verwerp H_0 als de p-waarde kleiner is dan of gelijk aan α . α kies je vooraf, meestal 0,05.
- Type I-fout: H_0 verwerpen terwijl ze waar is, met kans α . Type II-fout: H_0 niet verwerpen terwijl ze fout is.
- Kleiner α verkleint de ene fout en vergroot de andere; een grotere steekproef verkleint allebei.
- H_0 niet verwerpen is niet hetzelfde als H_0 aanvaarden.
- Noem altijd het significantieniveau bij je besluit.
- Significant is niet hetzelfde als belangrijk, zeker niet bij een grote steekproef.