

Populatie, steekproef en de steekproevenverdeling

Van een deel naar het geheel, en hoe hard je zo'n uitspraak mag maken.

1 Populatie en steekproef

De **populatie** is de volledige groep waarover je een uitspraak wil doen. De **steekproef** is het deel van die populatie dat je werkelijk onderzoekt. Je neemt een steekproef omdat de hele populatie onderzoeken **te duur of onmogelijk** is.

De **variabele** is het kenmerk dat je bij elk element van de steekproef meet: de lengte, het antwoord ja of nee, de wachttijd. In een stad van honderdduizend inwoners waar je er vierhonderd bevraagt, is de **steekproefgrootte vierhonderd** en niet honderdduizend.

Houd de symbolen uit elkaar. Links staat de populatie, rechts de steekproef. Ze zijn in de regel **niet precies gelijk**, en dat is geen fout maar de kern van het vak.

Wat	Populatie	Steekproef
gemiddelde	μ	$\bar{x}$ met een streepje
standaardafwijking	σ , de populatiestandaardafwijking	s , de steekproefstandaardafwijking
proportie	p	$\hat{p}$ met een dakje
grootte	N	n

Schrijven dat het steekproefgemiddelde μ is, is dus fout: **μ staat voor het populatiegemiddelde**. En dat populatiegemiddelde is meestal net wat je **niet** kent; als je het kende, hoefde je geen steekproef te nemen.

De **steekproefproportie** $\hat{p}$ met een dakje is het aandeel in je steekproef, dus altijd een getal tussen nul en één. Zeggen van de vierhonderd bevraagden er honderd ja, dan is $\hat{p}$ met een dakje gelijk aan **nul komma vijfentwintig**.

2 Een goede steekproef

Een **aselecte** steekproef is er een waarbij **elk lid van de populatie dezelfde kans heeft om gekozen te worden**. Een steekproef die een goede afspiegeling van de populatie is, heet **representatief**.

Vraag je alleen aan bezoekers van een sportclub hoeveel ze bewegen, dan is je steekproef **niet representatief** voor de hele bevolking, hoe veel mensen je er ook bevraagt. Daarom is een aselecte steekproef van driehonderd **betrouwbaarder** dan duizend mensen die je zelf uitkiest. **Groot is niet hetzelfde als goed.**

Variabiliteit is het woord van de bijlage voor het verschijnsel dat verschillende steekproeven uit dezelfde populatie verschillende resultaten geven. Een grotere steekproef geeft meestal een betere schatting, maar nooit een zekerheid.

3 De steekproevenverdeling

Stel dat je niet één maar **alle mogelijke** steekproeven van grootte n zou nemen en van elk het gemiddelde zou opschrijven. Die gemiddelden vormen samen de **steekproevenverdeling van het steekproefgemiddelde**. Je trekt ze nooit allemaal, maar je weet wel hoe ze eruitziet, en daar heb je alles aan: ze zegt je **hoe ver het gemiddelde van jouw ene steekproef waarschijnlijk van μ af ligt**.

Het formularium geeft twee benaderingen, elk met haar voorwaarden.

Het steekproefgemiddelde is bij benadering $N(\mu; \text{sigma gedeeld door de wortel uit } n)$, op voorwaarde dat **n minstens dertig** is.

De steekproefproportie is bij benadering normaal verdeeld met standaardafwijking **de wortel uit p maal $(1 - p)$ gedeeld door n** , op **drie** voorwaarden: **n is minstens dertig, $n \cdot p$ is minstens tien én $n \cdot (1 - p)$ is minstens tien**.

Het gemiddelde van de steekproevenverdeling van het steekproefgemiddelde is **gelijk aan μ** . Je zit dus gemiddeld juist; de vraag is alleen hoe ver je er in één steekproef naast kan zitten.

Gegeven	sigma gedeeld door de wortel uit n	Uitkomst
sigma = 10 en $n = 100$	10 gedeeld door 10	1
sigma = 15 en $n = 225$	15 gedeeld door 15	1
$p = 0,5$ en $n = 100$	wortel uit $(0,5 \cdot 0,5)$ gedeeld door 100	0,05

 **Weetje.** In de noemer staat de **wortel** uit n . Wordt n vier keer groter, dan wordt de spreiding van het steekproefgemiddelde **gehalveerd**, niet gevierendeeld. Wil je dubbel zo nauwkeurig meten, dan heb je vier keer zoveel mensen nodig.

4 Eerst de voorwaarden controleren

Controleer de voorwaarden **vóór** je de normale benadering gebruikt. Zijn ze niet voldaan, dan geldt de benadering niet en is je besluit niets waard.

Geval	$n \geq 30?$	$n \cdot p \geq 10?$	$n \cdot (1 - p) \geq 10?$	Mag het?
gemiddelde, $n = 45$	ja	—	—	ja
gemiddelde, $n = 25$	nee	—	—	nee
proportie, $n = 100$ en $p = 0,2$	ja	20, ja	80, ja	ja
proportie, $n = 100$ en $p = 0,6$	ja	60, ja	40, ja	ja
proportie, $n = 40$ en $p = 0,05$	ja	2, nee	38, ja	nee
proportie, $n = 200$ en $p = 0,02$	ja	4, nee	196, ja	nee
proportie, $n = 50$ en $p = 0,08$	ja	4, nee	46, ja	nee
proportie, $n = 500$ en $p = 0,03$	ja	15, ja	485, ja	ja

De klassieke fout bij een **proportie** is stoppen na de eerste voorwaarde. n is dan wel groot genoeg, maar bij een kleine p kan $n \cdot p$ nog altijd onder de tien blijven, en dan loopt het mis aan die kant.

 **Weetje.** De grootte van de populatie doet er niet toe. Een steekproef van duizend is in een land van elf miljoen even nauwkeurig als in een stad van vijftigduizend. In de formules staat alleen n , nergens N .

Onthoud dit

- Populatie = de hele groep, steekproef = het deel dat je onderzoekt. μ , σ en p horen bij de populatie; x met een streepje, s en p met een dakje bij de steekproef.
- Aselect betekent dat iedereen dezelfde kans heeft om gekozen te worden; representatief betekent een goede afspiegeling.
- Een kleine aselechte steekproef verslaat een grote die je zelf uitkiest.
- Steekproefgemiddelde: $N(\mu; \sigma / \sqrt{n})$, op voorwaarde dat n minstens dertig is.
- Steekproefproportie: standaardafwijking $\sqrt{p(1 - p)/n}$, op drie voorwaarden: $n \geq 30$, $n \cdot p \geq 10$ en $n \cdot (1 - p) \geq 10$.
- Vier keer meer metingen halveert de spreiding. De grootte van de populatie telt niet mee.