


Spreidingsdiagrammen, trendlijn en correlatie

Twee grootheden tegen elkaar uitzetten, en voorzichtig zijn met wat je eruit besluit.

1 Het spreidingsdiagram

In een **spreidingsdiagram** zet je voor elk element **één punt** met twee gemeten waarden. Je hebt er dus **twee numerieke variabelen** voor nodig; voor één variabele in groepen gebruik je iets anders. Een ander woord ervoor is **puntenwolk**.

Op de **horizontale as** staat de **onafhankelijke** variabele, op de **verticale as** de **afhankelijke**. Onderzoek je of meer studietijd een hoger punt geeft, dan is de studietijd onafhankelijk en het punt op de toets afhankelijk. Zet een leerling de schoolresultaten horizontaal en de studietijd verticaal, dan horen de assen omgewisseld.



Negen leerlingen. De trendlijn is $y = 1,07x + 6,6$ en r is 0,95: een sterke positieve samenhang.

Volgens de fiche maak je zo'n diagram **met ICT**, dus met de rekenapps van de examencommissie. Je tikt de twee kolommen in het rekenblad en vraagt het diagram op.

2 Welke vorm zie je?

Vorm van de wolk	Soort verband
rond een rechte van links onder naar rechts boven	positief lineair verband
rond een rechte van links boven naar rechts onder	negatief lineair verband
de ene verdubbelt als de andere verdubbelt	recht evenredig
de ene halveert als de andere verdubbelt	omgekeerd evenredig
een parabool	kwadratisch verband
een omgekeerde U	kwadratisch verband met een maximum in het midden
geen zichtbaar patroon	geen lineair verband — maar misschien wel een ander

Een **lineair** verband hoeft **niet door de oorsprong** te gaan; recht evenredig wel. En een spreidingsdiagram kan dus ook een verband tonen dat **niet rechtlijnig** is: meet je bij vijftig auto's de snelheid en de remafstand, dan groeit de remafstand sneller dan de snelheid en zie je een **kwadratisch** verband.

Ligt er één punt **heel ver** van de rest, dan gooi je het niet zomaar weg: je onderzoekt of het een **meetfout of een echt bijzonder geval** is.

3 De trendlijn

De **trendlijn** is de lijn die het verloop van de puntenwolk het best weergeeft. Haar voorschrift bepaal je **met ICT**: de rekenapp geeft je de vergelijking.

Lees ze zoals elke rechte. Het getal voor de x heet de **richtingscoëfficiënt**. Is de trendlijn $y = 2x + 5$, dan betekent de twee: **per eenheid die x stijgt, stijgt y met twee eenheden**.


Niet buiten je gegevens voorspellen. Een trendlijn is getrokken door de punten die je gemeten hebt. Buiten dat bereik weet je niet of ze nog klopt, en dan hoort ze er ook niet te staan. Daarom loopt de trendlijn in de tekening hierboven enkel van twee tot tien uur.

4 De correlatiecoëfficiënt r

De **correlatiecoëfficiënt r** drukt in één getal uit hoe sterk het **lineaire** verband is. Ze ligt **altijd tussen min één en plus één**. Het teken zegt de richting, de grootte de sterkte.

r	Samenhang volgens het formularium
0	geen samenhang
tussen 0 en 0,3	zwakke positieve samenhang
tussen 0,3 en 0,7	matige positieve samenhang
boven 0,7	sterke positieve samenhang
tussen 0 en -0,3	zwakke negatieve samenhang
tussen -0,3 en -0,7	matige negatieve samenhang
onder -0,7	sterke negatieve samenhang

Dus r gelijk aan **0,85** is een sterke positieve samenhang, **0,35** een matige, **0,2** een zwakke, en **min 0,5** een matige negatieve. **Min 0,9** betekent een sterk verband waarbij de ene daalt als de andere stijgt. Die vuistregels staan in het **formularium dat je bij het examen krijgt**, dus je hoeft ze niet uit het hoofd te kennen — ze lezen wel.



Dezelfde soort gegevens, maar nu met r gelijk aan 0,55: een matige positieve samenhang. De punten liggen veel losser rond de lijn.

Teken eerst, reken dan. Maak altijd eerst een spreidingsdiagram vóór je r berekent: r zegt **enkel iets over een lineair verband**, en je wil de vorm zien.

Daarom betekent **r gelijk aan nul niet** dat er zeker geen enkel verband is: een mooie omgekeerde U kan r nul geven terwijl het verband glashelder is. En een puntenwolk zonder zichtbaar patroon sluit een ander soort verband niet uit.

Twee onderzoekers kunnen allebei r gelijk aan 0,8 vinden met heel verschillend uitzijnde puntenwolken. Hetzelfde getal hoort bij verschillende vormen; **daarom kijk je altijd naar het diagram.**

5 Correlatie is geen causaliteit

Correlatie is samenhang, causaliteit is oorzaak en gevolg. Een sterke correlatie **bewijst niet** dat de ene grootheid de andere veroorzaakt. Dat is de belangrijkste zin van dit thema.

Waarneming	De echte verklaring
in de zomer worden meer ijsjes verkocht én verdrinken meer mensen	de warmte verklaart allebei
kinderen met grotere voeten lezen beter	de leeftijd verklaart allebei
wie meer melk drinkt, haalt hogere punten	misschien ontbijten die leerlingen simpelweg beter

In alle drie de gevallen zit er een **derde grootheid** achter die de twee andere stuurt. "Drink melk voor betere punten" is dus een krantenkop en geen besluit.

Onthoud dit

- Een spreidingsdiagram zet twee numerieke variabelen tegen elkaar: onafhankelijk horizontaal, afhankelijk verticaal.
- De trendlijn geeft het verloop weer; haar richtingsgetal zegt hoeveel y stijgt per eenheid x. Voorspel er niet mee buiten je meetbereik.
- r ligt tussen -1 en 1 . Tot $0,3$ zwak, tot $0,7$ matig, daarboven sterk. De vuistregels staan in het formularium.
- r meet enkel een lineair verband, dus teken eerst het diagram en reken dan.
- r gelijk aan nul betekent geen lineair verband, niet geen enkel verband.
- Correlatie bewijst geen oorzaak: zoek altijd naar een derde grootheid.

