

Spreadingsmaten en de boxplot

Hoe ver de gegevens uit elkaar liggen, en hoe je dat in één tekening zet.

1 Variatiebreedte, kwartielen en interkwartielafstand

Een **spreadingsmaat** zegt hoe ver de gegevens uit elkaar liggen. Het gemiddelde, de mediaan en de modus zijn er dus geen: die zeggen waar het midden ligt. De **variatiebreedte** is het verschil tussen de grootste en de kleinste waarde. Bij 2, 4, 6, 8, 10, 12, 14 en 16 is dat $16 - 2 =$ **veertien**. Ze **kan nooit negatief zijn**, en ze is vaak een slechte maat: ze gebruikt **enkel de twee meest extreme waarden**.

De **drie kwartielen** verdelen een gerangschikte dataset in vier gelijke delen. **Q2 is de mediaan**. Onder **Q1** ligt een kwart van de gegevens, boven **Q3** ook. Tussen Q1 en Q3 ligt dus **vijftig procent** van de gegevens.

Zo reken je Q1 en Q3. Rangschik eerst — anders betekent een plaats in de lijst niets. Q1 is de mediaan van de onderste helft, Q3 die van de bovenste helft. Bij een **oneven** aantal laat je de mediaan **buiten** allebei de helften.

Bij 1 tot en met 11: de mediaan is **6**, Q1 is de mediaan van 1 tot 5, dus **3**, en Q3 die van 7 tot 11, dus **9**. De interkwartielafstand is $9 - 3 =$ **6**.

Bij 2, 4, 6, 8, 10, 12, 14 en 16: de mediaan is $(8 + 10)$ gedeeld door 2, dus **9**; Q1 is de mediaan van 2, 4, 6 en 8, dus **5**, en Q3 die van 10, 12, 14 en 16, dus **13**.

De **interkwartielafstand** is $Q3 - Q1$. Ze is **minder gevoelig voor uitschieters** dan de variatiebreedte, want ze kijkt enkel naar de middelste helft. Is ze **nul**, dan heeft die hele middelste helft dezelfde waarde.

Twee klassen met dezelfde mediaan, de ene met een interkwartielafstand van 2 en de andere van 8: bij de tweede liggen de resultaten **veel verder uit elkaar**.

2 De standaardafwijking

De **standaardafwijking** meet hoeveel de waarden gemiddeld van het gemiddelde afwijken. Ze staat in **dezelfde eenheid als de gegevens**, en de bijlage noteert de steekproefstandaardafwijking met de letter **s**.

Ze **kan niet negatief zijn**: meldt iemand min drie, dan zit er een rekenfout in. Is ze **nul**, dan zijn alle waarden gelijk. En twee datasets met hetzelfde gemiddelde hebben **niet** automatisch dezelfde standaardafwijking — dat is net waarom je ze allebei vermeldt.


De standaardafwijking is **gevoeliger voor uitschieters** dan de interkwartielafstand, want elke afwijking telt mee, en de grote in het kwadraat. Bij een dataset met enkele extreme uitschieters kies je dus de **interkwartielafstand**: die is robuust.



Weetje. Een dataset met gemiddelde 50 en standaardafwijking 2: een waarde van **70** ligt dan **tien standaardafwijkingen** boven het gemiddelde. Dat is geen grote waarde meer, dat is een uitzonderlijke. Ga ze eerst nakijken voor je ze gebruikt.

3 De boxplot

Een **boxplot** zet **vijf getallen** in één tekening: het **minimum**, de **drie kwartielen** en het **maximum**. De **doos** loopt van Q1 tot Q3 en is dus de **middelste helft**; de **streep in de doos** is de **mediaan**.



De reeks 2 tot 16 met stap twee: minimum 2, Q1 vijf, mediaan negen, Q3 dertien, maximum 16.

Staat de streep **niet in het midden** van de doos, dan wijst dat op een **scheve** verdeling. Een **korte linkersnorhaan** en een **heel lange rechtersnorhaan** betekent scheef naar rechts, met uitgespreide hoge waarden.

De vuistregel voor uitschieters. Een waarde die verder dan **anderhalve interkwartielafstand** buiten de doos ligt, duid je als uitschieter aan.

Bij $Q1 = 10$ en $Q3 = 20$ is de interkwartielafstand tien, anderhalf keer tien is vijftien, dus de grenzen liggen bij $10 - 15 = \text{min vijf}$ en $20 + 15 = \text{vijfendertig}$.

Uit een boxplot kan je **niet** aflezen hoeveel gegevens er in de dataset zitten. Elk deel bevat per definitie een kwart, maar hoeveel dat er zijn, zegt de tekening niet.

Twee boxplots naast elkaar zijn daarom zo handig om groepen te vergelijken: je ziet in één beeld het **centrum**, de **spreiding** en de **uitschieters**. Zet ze wel op **dezelfde as**.

Bij een grote dataset bereken je de spreidingsmaten **met ICT**, met de rekenapps van de examencommissie.

Onthoud dit

- Variatiebreedte = grootste min kleinste, en gebruikt dus maar twee waarden.
- Q2 is de mediaan. Tussen Q1 en Q3 ligt de middelste helft; hun verschil is de interkwartielafstand.
- Rangschik eerst, en laat bij een oneven aantal de mediaan buiten de twee helften.
- De standaardafwijking staat in de eenheid van de gegevens, is nooit negatief en is nul als alles gelijk is.
- Bij uitschieters kies je de interkwartielafstand; de standaardafwijking is er gevoeliger voor.
- Een boxplot toont vijf getallen: minimum, Q1, mediaan, Q3 en maximum. Niet hoeveel gegevens er zijn.
- Uitschieter: verder dan anderhalve interkwartielafstand buiten de doos.