

Gegevens weergeven en samenvatten

Categorische en numerieke gegevens, de frequentietabel, de grafiek die bij je gegevens past, de centrummaten en de spreidingsmaten, en hoe een grafiek je om de tuin kan leiden.

1 Twee soorten gegevens

Voor je iets tekent of berekent, kijk je eerst **wat voor gegevens je hebt**.

Categorische gegevens zijn gegevens in groepen: haarkleur, vervoermiddel, lievelingsvak. Je kan ze tellen, maar **je kan ze niet zinvol optellen**: het gemiddelde van blauw en groen bestaat niet. **Numerieke gegevens zijn gegevens die je meet of telt**: lengte, leeftijd, het aantal broers en zussen. **Daarmee kan je wél rekenen**.

gegeven	soort
de lengte in centimeter	numeriek, je meet ze
het aantal broers en zussen	numeriek, je telt ze
de leeftijd in jaren	numeriek, je telt ze
de haarkleur	categorisch, het is een groep
het vervoermiddel naar school	categorisch, het is een groep

De frequentietabel zet elke waarde met haar aantal op een rij: links de waarden, rechts hoe vaak ze voorkomen. **De som van de frequenties is gelijk aan het aantal gegevens**, en dat is meteen je controle: komt die som niet uit, dan ben je een gegeven vergeten.

Zijn er te veel verschillende waarden, dan werk je met klassen. Bij lengtes van 1,52 tot 1,89 meter heeft bijna elke leerling een eigen waarde; dan groepeer je in klassen, bijvoorbeeld van 5 centimeter. **Voor lengtes van 150 tot 190 centimeter heb je vier klassen van 10 centimeter nodig**: 150 tot 160, 160 tot 170, 170 tot 180 en 180 tot 190.

De relatieve frequentie is het aandeel, meestal in procent: de frequentie gedeeld door het totaal. **Komen 20 van de 50 leerlingen met de bus, dan is de relatieve frequentie 40 procent**, want $20 : 50 = 0,4$. Dat getal laat je twee groepen van verschillende grootte toch vergelijken.

 **Weetje.** Een percentage verzwijgt hoeveel gegevens erachter zitten. “67 procent beveelt het aan” klinkt sterk, tot je leest dat er drie mensen bevraagd werden.

2 De grafiek die bij je gegevens past

Elke grafiek hoort bij een soort gegevens. **Kies je de verkeerde, dan is je grafiek niet fout gerekend maar wel onleesbaar.**

grafiek	waarvoor	hoe ze eruitziet
staafdiagram	categorische gegevens	losse staven met ruimte ertussen, één per categorie
histogram	numerieke gegevens in klassen	staven tegen elkaar, want de klassen sluiten aan
cirkeldiagram	delen van een geheel	partjes die samen 100 procent vormen
lijndiagram	een verloop in de tijd	een lijn die opeenvolgende momenten verbindt
dotplot	een kleine reeks metingen	één stip per gegeven, zo zie je meteen de vorm
boxplot	de spreiding van een reeks	de kwartielen en de mediaan in één beeld

Het verschil tussen een staafdiagram en een histogram zit in die ruimte. Bij een staafdiagram staan de staven los, want de categorieën staan los van elkaar. **Bij een histogram staan de staven tegen elkaar**, want 160 tot 170 sluit aan op 170 tot 180.

Een cirkeldiagram is niet geschikt om twintig categorieën te vergelijken: twintig partjes zijn niet van elkaar te onderscheiden. Een staafdiagram leest dan veel beter. En **een spreidingsdiagram toont geen verloop in de tijd**, dat doet een lijndiagram; daarover gaat het volgende hoofdstuk.

Op elke grafiek horen drie dingen te staan: een titel, een naam bij elke as en de eenheid van de getallen. Zonder naam bij de as en zonder eenheid is een grafiek niet te lezen.

3 De centrummaten

Een centrummaat vat een hele reeks samen in één getal. Er zijn er drie, en ze zeggen elk iets anders.

maat	wat ze is	voorbeeld
het gemiddelde	de som gedeeld door het aantal	4, 6 en 8 hebben gemiddelde 6, want $18 : 3 = 6$
de mediaan	de middelste waarde als je ze van klein naar groot zet	de mediaan van 3, 5, 9, 11 en 12 is 9: vijf waarden, dus de derde
de modus	de meest voorkomende waarde	ook bij categorische gegevens: de meest gekozen kleur

Bij een even aantal waarden neem je voor de mediaan het gemiddelde van de twee middelste. De mediaan van 2, 4, 6 en 10 is dus 5: $4 + 6 = 10$, en $10 : 2 = 5$.

Er kunnen ook twee modi zijn, als twee waarden even vaak voorkomen. En **de modus bestaat niet enkel bij numerieke gegevens**: ook bij een kleur of een vervoermiddel is er een waarde die het vaakst gekozen wordt.

Bij een uitschieter zegt de mediaan meer dan het gemiddelde. Neem de reeks 6, 7, 7, 8 en 32. **Het gemiddelde is 12**, want de som is 60; **de mediaan is 7**. Niemand van de eerste vier zit in de buurt van 12: **die ene uitschieter trekt het gemiddelde mee omhoog, terwijl de mediaan amper beweegt**, want die ligt vast door de middelste waarde.



De vier lage waarden liggen dicht bij de mediaan, en het gemiddelde ligt een stuk rechts van alle vier.


Een gemiddelde zegt dus niet altijd genoeg over een groep. Twee groepen met hetzelfde gemiddelde kunnen heel anders gespreid zijn: daarvoor heb je de spreidingsmaten nodig.

4 De spreidingsmaten

Een spreidingsmaat zegt hoe ver de gegevens uiteen liggen. Ook hier zijn er drie.

maat	wat ze is	voorbeeld
de variatiebreedte	het grootste min het kleinste	bij 7, 12 en 20 is ze 13, want $20 - 7 = 13$
de interkwartielafstand	het derde kwartiel min het eerste	de breedte van de middelste helft; uitschieters tellen er niet in mee
de standaardafwijking	hoe ver de gegevens gemiddeld van het gemiddelde liggen	klein is dicht bij het gemiddelde, groot is sterk gespreid

De boxplot tekent de spreiding. Je leest er **de kwartielen en de mediaan** op af, en daarmee ook het minimum en het maximum: vijf getallen in één beeld. **De doos is de middelste helft van de gegevens**, de streep erin is de mediaan.



Deze reeks loopt van 2 tot 20, de middelste helft ligt tussen 6 en 14, en de mediaan ligt op 10.

Bij die reeks is **de variatiebreedte 18** ($20 - 2$) en **de interkwartielafstand 8** ($14 - 6$). **De interkwartielafstand is dus een stuk kleiner dan de variatiebreedte, en net dat is haar nut:** ze kijkt enkel naar de middelste helft en laat de uiteinden links liggen.

Weetje. Op een boxplot zie je niet hoeveel gegevens erachter zitten. Een doos van tien metingen ziet er precies hetzelfde uit als een doos van duizend.

5 Een grafiek kritisch lezen

Een grafiek kan kloppen en toch misleiden. De bekendste manier is **een afgeknotte as: een y-as die niet bij nul begint kan een klein verschil groot doen lijken**. Zet je twee staven van 98 en 100 op een as die bij 97 begint in plaats van bij nul, dan steekt de ene er 1 boven uit en de andere 3: **de tweede staaf lijkt zo drie keer zo hoog als de eerste**, terwijl ze maar 2 procent verschillen.

waar je op let	waarom
waar de assen beginnen	een afgeknotte as blaast een verschil op
welke eenheid er staat	zonder eenheid betekent een getal niets
hoeveel gegevens erachter zitten	een percentage van 4 mensen zegt iets heel anders dan een percentage van 4000

Dat kritisch lezen is zelf leerstof. Op het examen krijg je een grafiek en de vraag wat je eruit mag besluiten; **het juiste antwoord is vaak dat je er minder uit mag besluiten dan de grafiek suggereert.**