


Verbanden tussen twee grootheden

Het spreidingsdiagram en de puntenwolk, de trendlijn en wat je ermee mag voorspellen, de correlatiecoëfficiënt, en waarom samenhang nog geen oorzaak is.

1 Het spreidingsdiagram

Tot nu ging het over één grootte tegelijk. **Wil je twee grootheden naast elkaar leggen, dan teken je een spreidingsdiagram: één punt per meetpaar. Elk punt heeft twee waarden**, een op de x-as en een op de y-as. **Er horen dus twee waarden bij elk punt**, en die twee komen van dezelfde persoon of hetzelfde voorwerp.

De wolk punten noem je de puntenwolk, en haar vorm verradt het verband. **Je gebruikt een spreidingsdiagram net om een verband tussen twee grootheden te zien**: je merkt meteen of de punten een richting hebben.



Tien leerlingen: de kleinste meet 152 centimeter en heeft maat 36, de grootste meet 182 centimeter en heeft maat 44.

wat je ziet	wat het betekent
de punten stijgen	een positief verband : hoe hoger x, hoe hoger y
de punten dalen	een negatief verband : hoe hoger x, hoe lager y
geen richting	geen verband : de punten liggen verspreid

In een spreidingsdiagram van lengte en schoenmaat stijgen de punten: grotere mensen hebben een grotere maat. Een dalend verband vind je bijvoorbeeld tussen schermtijd en uren slaap. **Een spreidingsdiagram toont geen verloop in de tijd**, dat doet een lijndiagram, uit het vorige hoofdstuk.

Drie dingen lees je uit een spreidingsdiagram: de richting van het verband, hoe sterk het verband is en of er uitschieters zijn. Een percentage lees je er niet uit.

Bij een goed spreidingsdiagram staat er een naam bij elke as, de eenheid erbij en een passende schaal. De punten verbinden hoort er niet bij: dan maak je er een lijndiagram van, en dat zegt iets anders.

2 De trendlijn

De trendlijn is de rechte die het patroon van de puntenwolk volgt. Ze loopt zo dicht mogelijk bij alle punten, zonder er per se door te gaan: een trendlijn hoeft niet door alle punten te gaan, en door alle punten gaan lukt meestal niet eens.

Teken je ze met de hand, dan leg je ze zo dat er evenveel punten boven als onder liggen. Zo ligt ze zo dicht mogelijk bij de hele wolk. Op de grafische rekenmachine laat je ze berekenen; dan krijg je er meteen de vergelijking bij.

Waarvoor dient ze? Om een voorspelling te doen. Met haar vergelijking schat je een y bij een x die je niet gemeten hebt. In de tekening hierboven lees je zo af welke maat je verwacht bij iemand van 172 centimeter.

valkuil	waarom
ver buiten de gemeten waarden voorspellen	het verband kan daar anders zijn: buiten het bereik van je metingen weet je niet of de rechte nog klopt
een uitschieter laten staan zonder te kijken	één punt ver weg kan de trendlijn flink doen kantelen
een rechte opleggen aan een kromme wolk	een trendlijn is niet altijd een rechte; vaak wel, maar een verband kan ook krom zijn

Kijk dus altijd eerst naar de wolk zelf, en pas daarna naar de rechte. Daarom begint elke oefening met tekenen en niet met rekenen.

 **Weetje.** Een trendlijn heet ook een regressielijn. Dat woord komt van een onderzoek uit 1886 over de lengte van ouders en kinderen, waarin de kinderen telkens naar het gemiddelde toe “terugkeerden”.

3 De correlatiecoëfficiënt

Correlatie is samenhang tussen twee grootheden, meer niet. **De correlatiecoëfficiënt zet die samenhang in één getal**, en **dat getal ligt altijd tussen min 1 en 1**.

waarde	wat ze zegt
1	een perfect stijgend verband: alle punten liggen precies op een stijgende rechte
0,9	een sterk stijgend verband: de punten liggen bijna op een stijgende rechte
0,1	bijna geen verband: de punten liggen bijna richtingloos
0	geen lineair verband: de punten liggen zonder richting verspreid
-0,8	een sterk dalend verband
-1	een perfect dalend verband

Onthoud de twee helften van dat getal: **het teken geeft de richting, de grootte geeft de sterkte**. Een correlatie van min 1 is dus niet zwakker dan een van 0,5, maar net het sterkst mogelijke verband; de sterkst mogelijke waarden zijn 1 en min 1. Kijk naar de grootte, niet naar het teken.

Bij de tien leerlingen hierboven is de correlatiecoëfficiënt ongeveer 0,99: bijna 1, en inderdaad liggen de punten bijna op een rechte.

Eén beperking telt altijd mee: de correlatiecoëfficiënt zegt enkel iets over een lineair verband. Een duidelijk krom verband kan toch een correlatie dicht bij nul geven, en dan is nul niet “geen verband” maar “geen rechte”. Opnieuw: eerst de wolk bekijken.

4 Correlatie is geen causaliteit

Dit is het hart van het hoofdstuk: correlatie is geen causaliteit. Samen bewegen is niet hetzelfde als elkaar veroorzaken, en een sterke correlatie bewijst dus niet dat het ene het andere veroorzaakt.

mogelijke verklaring	voorbeeld
het ene veroorzaakt het andere	meer uren studeren en een beter resultaat
een derde factor verklaart beide	ijsjes en zwemongevallen: de warmte duwt beide omhoog
het is toeval	twee reeksen die een tijdlang toevallig samen stijgen

Een derde factor is iets dat beide verklaart, ook wel een **verstorende factor** genoemd. **Het aantal ijsjes en het aantal zwemongevallen stijgen samen omdat het warm weer is**, niet omdat ijsjes gevaarlijk zijn. **Stijgen het aantal ooievaars en het aantal geboorten samen in een land, dan besluit je dus enkel dat er samenhang is**: het bekendste schijnverband uit de handboeken.

Hoe toon je een oorzakelijk verband dan wel aan? Met een opgezet experiment: je verandert één ding en houdt de rest gelijk. **Dat kan een grafiek niet**. En **voor je uit een grafiek een oorzaak besluit, zoek je naar een verklaring: een verband zonder plausibele verklaring blijft een vermoeden**.

Uit een correlatiecoëfficiënt van 0,95 mag je drie dingen besluiten: de punten liggen dicht bij een rechte, het verband is stijgend en voorspellen lukt hier redelijk goed. Over oorzaak zegt dat getal niets.

 **Weetje.** Er bestaan hele verzamelingen van zulke schijnverbanden, bijvoorbeeld tussen het aantal films met een bepaalde acteur en het aantal echtscheidingen in een staat. Zoek er lang genoeg, en je vindt altijd twee reeksen die samen bewegen.