

Statistiek: voorstellingen, centrum en spreiding

Soorten gegevens, frequentietabellen en diagrammen, en de maten voor centrum en spreiding.

1 Soorten gegevens

Soort	Wat het is	Voorbeeld
numeriek	getallen waarmee je kan rekenen	de lengte in centimeter
categorisch, niet-geordend	categorieën zonder volgorde	haarkleur, gemeente, merk
categorisch, geordend	categorieën met een natuurlijke volgorde	zeer goed, goed, zwak

Gegevens staan **niet-gegroepeerd** (elke losse waarde apart) of **gegroepeerd** in **klassen**. Bij veel verschillende waarden is groeperen overzichtelijker. Het **klassenmidden** is het gemiddelde van de twee grenzen: bij de klasse van 10 tot 20 is dat 15, bij 20 tot 30 is dat 25. Daarmee reken je verder als je de losse waarden niet meer hebt.

2 De frequentietabel

De **absolute frequentie** is hoeveel keer een waarde voorkomt. De **relatieve frequentie** is welk deel van het geheel dat is, meestal in procent: 10 fietsers op 25 leerlingen is $10/25 = 40\%$; 20 op 50 is ook 40 %. Alle relatieve frequenties samen geven **100 %**.

3 De voorstellingen

Diagram	Waarvoor	Kenmerk
staafdiagram	categorieën vergelijken	de staven staan LOS van elkaar
histogram	gegevens in klassen	de staven RAKEN elkaar
cirkeldiagram	het aandeel in één geheel	alles samen is 100 %
lijndiagram	een verloop in de tijd	de lijn toont stijging of daling
boxplot	spreiding in vijf getallen	kleinste, drie kwartielen, grootste
dotplot	elke meting apart	één punt per meting boven haar waarde

Het verschil tussen een staafdiagram en een histogram zit in de ruimte tussen de staven: bij **klassen** sluiten de intervallen op elkaar aan, dus raken de staven elkaar. Bij losse categorieën niet.

Een **cirkeldiagram** is niet geschikt voor een verloop in de tijd; daarvoor neem je een lijndiagram. En bij veel categorieën wordt een cirkeldiagram onleesbaar.

Een **dotplot** zet elke meting als een punt boven haar waarde. Zo zie je meteen waar de waarden zich opstapelen en welke er ver vanaf liggen.

4 De vorm van een verdeling

Een verdeling is **symmetrisch** als links en rechts van het midden ongeveer evenveel ligt, en **scheef** als dat niet zo is. Bij een **rechtsscheve** verdeling ligt het grootste deel links en loopt er een lange staart naar rechts. Zo zien lonen eruit: veel mensen rond een gewoon loon, enkelen met heel veel meer.

Een **uitschieter** is een waarde die ver van de rest ligt. Ga altijd na of het een meetfout is of een echte waarneming. Toont een dotplot twee **clusters**, twee opstapelingen ver uit elkaar, dan zit er vaak een verborgen verschil achter: twee klassen samen, twee toestellen, twee meetdagen.

5 De centrummaten

Maat	Hoe je ze vindt	Voorbeeld
rekenkundig gemiddelde	de som gedeeld door het aantal	4, 8, 10, 14 geeft $36 : 4 = 9$
mediaan	de middelste van de gerangschikte reeks	3, 7, 8, 12, 20 geeft 8
modus	de waarde die het vaakst voorkomt	2, 3, 3, 5, 9 geeft 3

Bij een **even** aantal waarden is de mediaan het gemiddelde van de twee middelste: bij 4, 6, 9 en 11 is dat 7,5.

Een reeks kan **twee modi** hebben, als twee waarden even vaak én het vaakst voorkomen. En de modus is de enige centrummaat die ook bij **categorische** gegevens werkt: met haarkleuren kan je niet rekenen, maar je kan wel tellen welke het vaakst voorkomt.

Het **gemiddelde is gevoelig voor uitschieters**, de mediaan niet. Bij lonen trekken een paar heel hoge bedragen het gemiddelde omhoog, terwijl de mediaan enkel kijkt wie in het midden staat. Alleen bij een symmetrische verdeling vallen de twee ongeveer samen.

6 De spreidingsmaten

Het centrum alleen zegt te weinig. Twee klassen kunnen hetzelfde gemiddelde hebben terwijl de punten in de ene klas veel verder uit elkaar liggen. Daarvoor heb je een **spreidingsmaat** nodig.

Maat	Wat ze is	Gevoelig voor uitschieters?
variatiebreedte	de grootste min de kleinste waarde	ja, heel erg
kwartielen	de waarden die een kwart, de helft en drie kwart onder zich laten	nee
interkwartielafstand	het derde kwartiel min het eerste	nee
standaardafwijking	hoe ver de waarden gemiddeld van het gemiddelde liggen	ja

Het **eerste kwartiel** laat een kwart van de gegevens onder zich, het **tweede** is de mediaan, het **derde** laat driekwart onder zich. De **interkwartielafstand** is de breedte van de **doos van de boxplot**, en die doos bevat precies de **middelste helft** van de gegevens. Omdat de uiterste waarden erbuiten vallen, is die maat ongevoelig voor één uitschieter, terwijl de variatiebreedte er meteen door opblaast.

Een **kleine standaardafwijking** betekent dat de waarden dicht bij elkaar liggen. Heeft klas A bij hetzelfde gemiddelde een grotere standaardafwijking dan klas B, dan liggen in klas A de punten verder uit elkaar.

Onthoud dit

- Numeriek is rekenbaar; categorisch is geordend (zeer goed, goed, zwak) of niet.
- Klassenmidden is het gemiddelde van de twee klassengrenzen.
- Absolute frequentie is het aantal, relatieve het aandeel; samen 100 %.
- Staafdiagram: staven los. Histogram: staven raken elkaar.
- Cirkeldiagram voor aandelen, lijndiagram voor verloop in de tijd.
- Boxplot: kleinste, drie kwartielen, grootste. De doos is de middelste helft.
- Gemiddelde is de som gedeeld door het aantal; mediaan is de middelste; modus komt het vaakst voor.
- Bij een even aantal is de mediaan het gemiddelde van de twee middelste.
- Het gemiddelde is gevoelig voor uitschieters, de mediaan niet.
- Interkwartielafstand is $Q3 - Q1$ en is ongevoelig voor uitschieters.
- De standaardafwijking meet hoe ver de waarden gemiddeld van het gemiddelde liggen.